

YAMNet Mean + Logistic Regression Baseline v1

本文件是 frozen detector baseline `yamnet_mean_lr_v1` 的實驗紀錄，不是使用說明。表格與數值直接整理自下列 machine-readable artifact snapshot：

- `artifacts/baselines/yamnet_mean_lr_v1.json`
- `artifacts/cross_match/evaluation/cross_match_metrics.json`
- `artifacts/cross_match/evaluation/calibration/calibration_metrics.json`
- `artifacts/cross_match/evaluation/calibration/calibration_summary.csv`

1. 實驗目的

本實驗的任務是對 3 秒 audio window 執行 crowd cheer binary detection。Baseline 的目的，是驗證 YAMNet pretrained representation 加上 linear classifier，是否具備跨羽球比賽的歡呼辨識能力。

2. Frozen Model Configuration

項目	Frozen value
<code>baseline_id</code>	<code>yamnet_mean_lr_v1</code>
YAMNet identifier	https://tfhub.dev/google/yamnet/1
Sample rate	16,000 Hz mono
Window / hop / post-padding	3.0 s / 1.0 s / 3.0 s
Pooling	YAMNet patch embeddings 沿 patch axis 取 mean
Embedding dimension	1024
Preprocessing	training-fold <code>StandardScaler</code>
Classifier	<code>LogisticRegression</code>
<code>C</code>	1.0
Solver	<code>lbfgs</code>
<code>max_iter</code>	2000
<code>class_weight</code>	<code>None</code>
Threshold	0.5

此 baseline 已 freeze。後續 diagnostic 不會改變 YAMNet、pooling、classifier parameters 或 threshold。

3. Dataset

Match	Samples	Cheer	No cheer
<code>match_001</code>	100	33	67

Match	Samples	Cheer	No cheer
match_002	100	31	69
match_003	100	55	45
match_004	100	31	69

每場資料皆為 100 samples，來自 100 個 unique current segments。Sampling 採用 segment-diverse deterministic sampling，標籤由 blind human labeling 產生，ambiguous sample 數量為 0。Historical labels 不參與此 baseline 的 sampling、training 或 evaluation。

4. Evaluation Protocol

Evaluation 採 Leave-One-Match-Out (LOMO)。每個 fold 將一場完整 match 留作 held-out test match，其餘三場作為 training data；每個 fold 為 300 training samples 與 100 test samples。

`StandardScaler` 只能在 training fold 上執行 fit，再套用至 held-out match。這不是 random window split，且同一 held-out match 的 windows 不會進入該 fold 的 training data。

5. LOMO Results

Held-out match	Accuracy	Precision	Recall	F1	ROC-AUC	Average Precision
match_001	0.940	0.966	0.848	0.903	0.990	0.983
match_002	0.870	1.000	0.581	0.735	0.934	0.904
match_003	0.870	0.850	0.927	0.887	0.958	0.968
match_004	0.850	0.711	0.871	0.783	0.947	0.907
Macro mean	0.883	0.882	0.807	0.827	0.957	0.940

各 fold confusion matrix 的排列為 `[[TN, FP], [FN, TP]]`：

Held-out match	TN	FP	FN	TP
match_001	66	1	5	28
match_002	69	0	13	18
match_003	36	9	4	51
match_004	58	11	4	27

ROC-AUC 衡量 ranking/discrimination，不能解讀為 accuracy。

6. Per-Match Observations

- match_001 的 ROC-AUC 與 Average Precision 最高，在目前四個 held-out matches 中 discrimination 最強。
- match_002 precision 為 1.000，但 recall 為 0.581，代表 threshold 0.5 下漏掉較多 positive samples。
- match_003 recall 為 0.927，並維持 0.850 precision。


- `match_004` recall 為 0.871，高於 0.711 precision。
- 四個 held-out matches 的 ROC-AUC 均大於 0.93。

以上是目前資料的 descriptive interpretation，不代表已證明模型可普遍泛化至所有羽球比賽。

7. Calibration Diagnostic

Match	Prevalence	Predicted Positive Rate	Brier Score	Log Loss	ECE	Positive Probability Median	Negative Probability Median
<code>match_001</code>	0.330	0.290	0.0380	0.1246	0.0375	0.9993	0.001988
<code>match_002</code>	0.310	0.180	0.1124	0.4801	0.1310	0.6182	0.000249
<code>match_003</code>	0.550	0.600	0.1007	0.3402	0.0958	0.9981	0.007030
<code>match_004</code>	0.310	0.380	0.1209	0.5277	0.1318	0.9998	0.000209

ROC-AUC 與 Average Precision 衡量 discrimination；Brier score、Log Loss 與 reliability diagram 對 probability calibration 更敏感。ECE 使用固定 10 個 uniform bins，應與其他 calibration evidence 一起解讀，而不是單獨視為完整結論。



8. match_002 vs match_004

match_002 與 match_004 的 observed cheer prevalence 都是 31%，但 threshold 0.5 下 predicted positive rate 分別為 18% 與 38%。Positive probability median 也分別為 0.6182 與 0.9998；相較之下，兩場 negative probability median 都接近零。

這表示不同 match 存在不同 score-distribution behavior，尤其反映在 positive-class scores 與 threshold crossing。這是 descriptive evidence，不代表 causal domain shift 已被證明。

9. Current Interpretation

YAMNet mean-pooled embeddings 加上 Logistic Regression，在目前四場 clean matches 的 LOMO evaluation 中呈現穩定的 cross-match discrimination ability。主要剩餘問題之一，是不同 match 間的 score calibration 與 threshold behavior。

本結果不應描述成「95.7% accuracy」；0.957 是 macro ROC-AUC，而 macro accuracy 是 0.883。這份實驗也尚未證明模型可泛化至所有羽球比賽，更不代表 cheer detection 已完全解決。

10. Limitations

- 目前只有 4 個 matches。
- 每場只有 100 個 labeled samples。
- Match domain diversity 仍有限。
- Classification threshold 固定為 0.5。
- 尚未進行 calibration fitting。
- Cheer intensity 尚未實作。
- Final untouched external validation 尚未完成。
- 每場只有 100 samples，10-bin reliability curve 的個別 bin 估計可能不穩定。

11. Next Steps

1. Train/export deployable final detector。
2. 實作 cheer intensity。
3. 實作 segment-level aggregation。
4. 整合 upstream `modules/audio_highlight`。
5. 執行 runtime benchmark。
6. 執行 untouched unseen-match validation。
7. 持續增加 match diversity。

Calibration fitting 與 threshold tuning 尚未決定；本實驗沒有加入相關結果。

12. Reproduction

建立每場 canonical features：

```
uv run audio-highlight build-features --match-id match_001
uv run audio-highlight build-features --match-id match_002
uv run audio-highlight build-features --match-id match_003
uv run audio-highlight build-features --match-id match_004
```

執行四場 LOMO evaluation：

```
uv run audio-highlight evaluate `
  artifacts/match_001/features/features.npz `
  artifacts/match_002/features/features.npz `
  artifacts/match_003/features/features.npz `
  artifacts/match_004/features/features.npz `
  --output-dir artifacts/cross_match/evaluation
```

從既有 OOF predictions 執行 calibration diagnostic：

```
uv run audio-highlight diagnose-calibration `
  --predictions artifacts/cross_match/evaluation/cross_match_predictions.csv `
  --output-dir artifacts/cross_match/evaluation/calibration
```

13. Artifacts

- artifacts/baselines/yamnet_mean_lr_v1.json
- artifacts/cross_match/evaluation/cross_match_metrics.json
- artifacts/cross_match/evaluation/cross_match_predictions.csv
- artifacts/cross_match/evaluation/calibration/calibration_metrics.json
- artifacts/cross_match/evaluation/calibration/calibration_summary.csv
- artifacts/cross_match/evaluation/calibration/all_matches_reliability.png

Probability-distribution 與 per-match reliability plots 位於

artifacts/cross_match/evaluation/calibration/, 檔名分別為

match_00x_probability_distribution.png 與 match_00x_reliability.png。本文件只以 relative path 引用既有圖片，沒有複製 binary image。